Red Hat › OPENSHIFT AI

—— AGENTIC AI WEBINAR · JUL 2026

Agentic AI in regulierten Umgebungen

Modelle, Tools und Guardrails als Platform-Infrastruktur – nicht als Application Code.

ON-CLUSTER INFERENCE | SERVER-SIDE ORCHESTRATION | TOOL GOVERNANCE | THIN APPLICATION

Nikolaus Lemberski · Senior Specialist Solution Architect, Application Platform · Red Hat

Was ist Agentic AI?



—— DAS PROJEKT

Was wir bauen und warum

Ein Patient Triage Assistant – ein KI-Agent, der Triage-Pflegekräfte bei der Patientenaufnahme unterstützt. Er sucht Patientenakten, bewertet die Dringlichkeit von Symptomen, prüft Medikamenteninteraktionen und bucht Facharzttermine – alles in natürlicher Sprache.

- **Vollständig on-premise:** Modelle, Tools und Patientendaten bleiben im Cluster. Keine Cloud-LLM-APIs. HIPAA-konform durch Architektur.
- **Open-Source Stack:** OpenShift AI, Llama Stack (OGX), Quarkus MCP Server, vLLM – kein Vendor Lock-in.
- **Agentisch, kein Chatbot:** Der Agent ruft eigenständig Tools auf und verkettet Ergebnisse. Eine Nachricht löst den kompletten Workflow aus.
- **Platform-managed:** Modellwechsel, Tools hinzufügen, Guardrails aktivieren – alles Platform-Operationen. Keine Änderungen am Application Code.

—— DER STACK

Drei Bausteine, eine Plattform

MODEL SERVING

vLLM auf OpenShift AI

Qwen 3.5 9B als InferenceService CR auf einer GPU, nur cluster-intern erreichbar. vLLM: High-Throughput Inference Engine mit PagedAttention und Continuous Batching. OpenAI-kompatible API — modellagnostisch.

MIDDLEWARE

Llama Stack / OGX

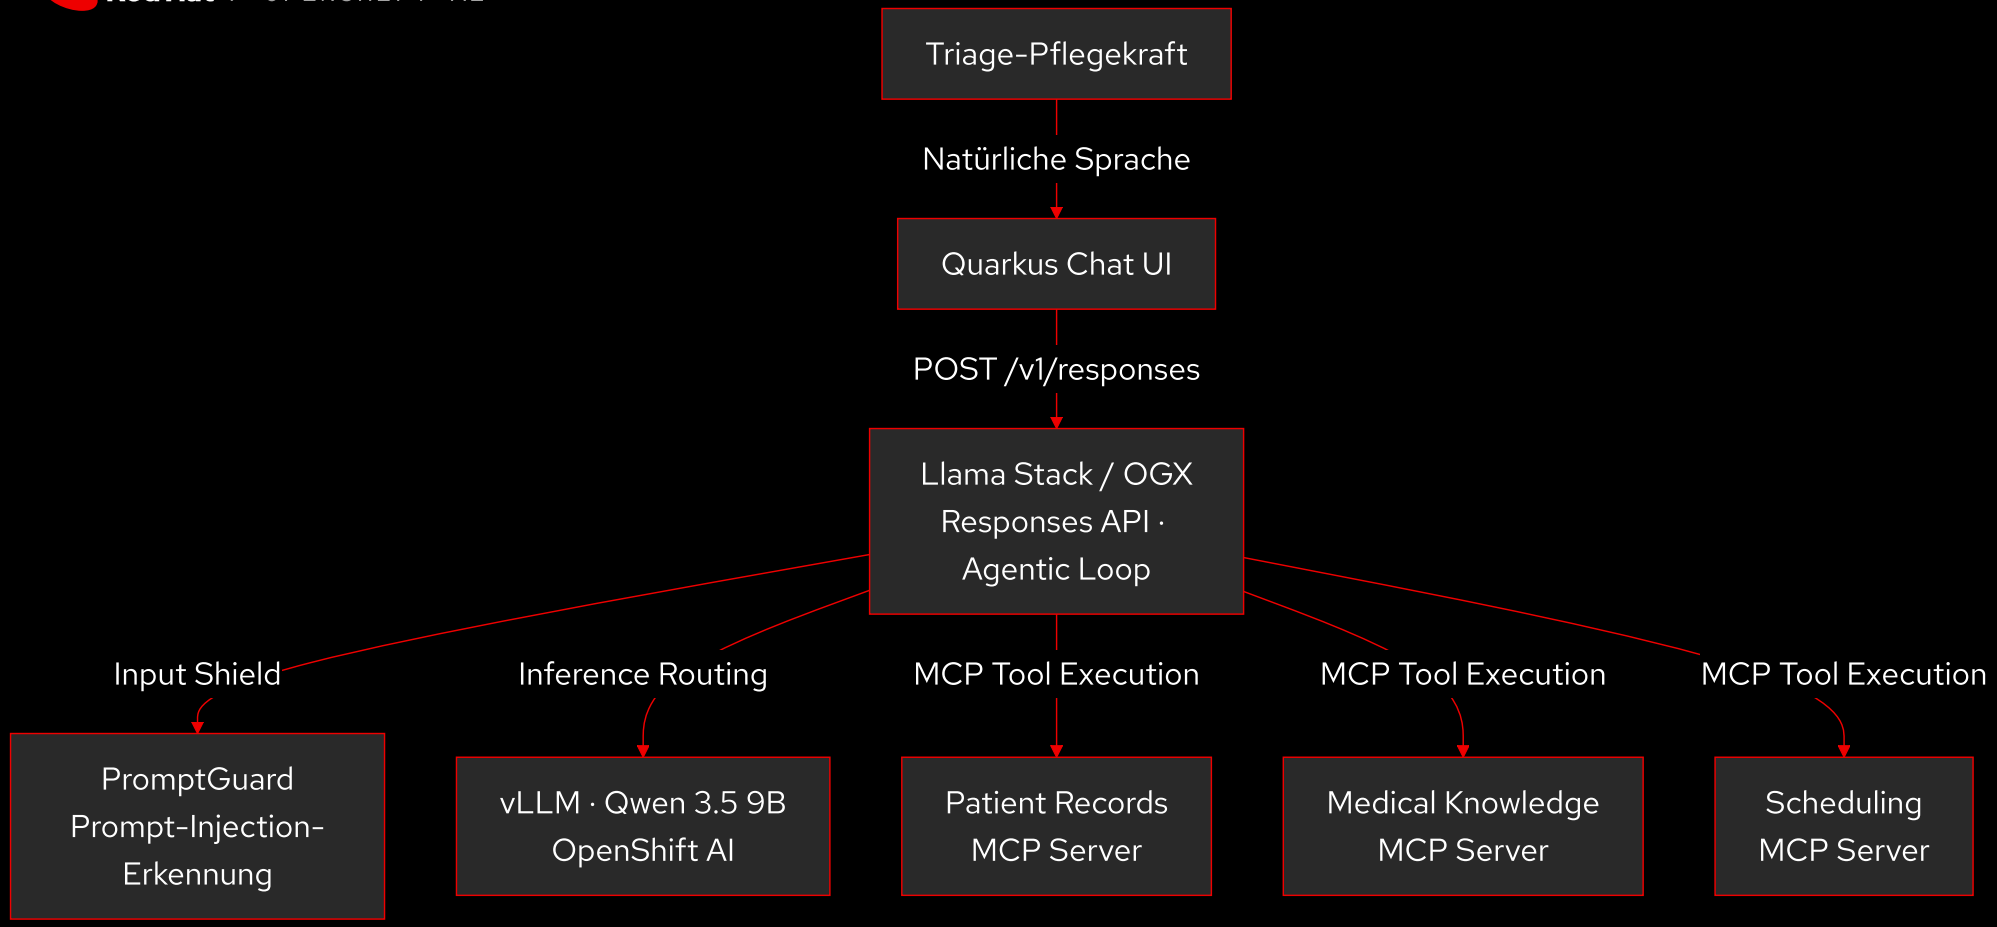
`POST /v1/responses` — der gesamte Agentic Loop läuft server-seitig. Model Routing, MCP Connectors und Guardrails als Config. Deployed via Operator.

TOOL-INTEGRATION

MCP Server

Offener Standard für Tool Discovery. Drei Quarkus MCP Server: Patientenakten, medizinisches Wissen, Terminplanung. Komponierbar via Streamable HTTP.

Red Hat › OPENSHIFT AI



Die App stellt eine Frage, Llama Stack liefert die fertige Antwort. Alle Tool-Aufrufe laufen server-seitig.

Demo Time!

Nikolaus Lemberski
Senior Specialist Solution Architect, Application Platform · Red Hat